

Métodos de Investigación - AP2107

Statistics: "science dealing with data about the condition of a state or community"

Gottfried Aschenwall, 1770

Universidad de O'Higgins
Instituto de Ciencias Sociales
Rancagua, Chile

Última actualización: September 28, 2020.
Descarga la última versión [aquí](#).

Aspectos Logísticos

Profesor: Héctor Bahamonde, PhD.
e: hector.bahamonde@uoh.cl
w: www.HectorBahamonde.com
Zoom ID: 951-326-1038.
Office Hours (Zoom): Toma una hora [aquí](#).

Hora de cátedra: Martes 12:00—13:30, Jueves 12:00—13:30
Lugar de cátedra: Zoom (no hay clases presenciales este semestre).

Acceso a materiales del curso: [aquí](#).

Ayudante de cátedra (TA): Gonzalo Barría (Mg.).
e: gonzalo.barría@uoh.cl
Zoom ID: 988-891-7227.
TA Bio: Gonzalo Barría es Cientista Político (PUC) y Magíster en Ciencia Política (PUC).
Hora de ayudantía: *On-demand*.
Lugar de ayudantía: Zoom (no hay ayudantías presenciales este semestre).

Carrera: Administración Pública.
Semestre/Año: Sexto Semestre/2020.
SCT: 6.
Horas semanales: Cátedra (45-60 minutos vía Zoom), Ayudantía (45-60 minutos vía Zoom).

Motivación: ¿Por qué tomar este curso?

*¿Qué efecto tiene la educación sobre los ingresos? ¿Cómo podemos evaluar los efectos de una reforma educacional?
¿La legalización de las drogas aumenta su consumo? ¿Qué candidato/a ganaría la elección presidencial si ésta fuera mañana?*

Las entidades públicas guían sus decisiones estratégicas en base a información cuantificable, i.e. datos.

Esto ha tomado incluso más importancia en la actualidad, donde ha habido una digitalización de los datos sociales. Es fundamental que los científicos sociales en general sepan cómo usar estos datos. Aún más, el quehacer social en general, está constantemente produciendo datos. Cada vez que usas *Twitter*, pides un *Uber*, envías un e-mail, votas, respondes una encuesta, estás produciendo datos sociales. Piensa en lo siguiente: si bien es cierto que hace unos diez años atrás *faltaban* datos, hoy en día los datos *sobran*. El desafío actual consiste en saber cómo analizarlos correctamente, y así ayudar a los tomadores de decisiones. Esto es importante. Mañana tu podrías ser un/a analista en una de las decenas de Departamentos de Estudios repartidas en la administración del Estado. **Este curso te prepara para ese mundo** (incluyendo el mundo de la consultoría).

Aunque lo que aprenderemos es altamente numérico y matemático, no te confundas. Estos métodos no son infalibles, y no nos contarán “la verdad” (si es que algo así existiera). Aún necesitas ser muy crítico(a). Como verás, **la estadística inferencial (que es el objeto de este curso) es un arte, no una ciencia**. Los números nos sugerirán ciertas ideas, pero aun así nuestro trabajo será *interpretar* estos resultados. No seas obediente. Se crítico/a y auto-crítico/a. Sospecha de tus propios resultados y el de los demás. Mal que mal, estaremos haciendo **inferencias** (no *certezas*) estadísticas. Como veremos, el fantasma de este semestre se llamará *incertidumbre*.

Este curso considera un énfasis especial en la *causalidad*. La *inferencia causal* ha llegado para quedarse en las ciencias sociales. ¿Bajo qué condiciones podemos decir que X *causa* Y? Más que una cuestión matemática, la causalidad toca en muchos aspectos la filosofía de las ciencias. Este semestre aprenderemos qué relación tiene la experimentación con la causalidad, cómo podemos hacer experimentos en ciencias sociales, y cómo podemos emular un experimento (usando ciertos métodos estadísticos) cuando no podemos ni debemos hacer uno.

Honestamente, espero que este curso cautive tu atención, y simiente tu curiosidad intelectual, sobre todo, mostrándote que nuestro objeto de estudio (la sociedad) es apasionante.

Bienvenid@s!

Propósito Formativo

El objetivo de este curso es introducir al/la alumno/a a los métodos econométricos básicos para el análisis de datos. El curso avanza progresivamente en distintos tópicos en regresión lineal y métodos no lineales. La principal característica es la introducción a modelos de regresión lineal para que en cursos más avanzados puedas estudiar otro tipo de estimaciones.

Objetivos Generales del Curso

El gran objetivo de este curso, es poder generar en la/el estudiante la capacidad de razonamiento crítico, desde un punto de vista empírico.

El lenguaje que aprenderemos este semestre será R, el lenguaje de programación más usado en las ciencias sociales. Esto tiene varias ventajas. R es gratis y corre en todas las plataformas disponibles. Segundo, es un lenguaje orientado a “objetos”. Esto significa—tercero—que fuerza al/la estudiante a realmente pensar en el proceso matemático/estadístico detrás del análisis que se está haciendo. Al contrario de otros *softwares* estadísticos como SPSS y Stata, donde el/la usuario(a) simplemente aprieta botones sin saber lo que ocurre realmente, R necesita que le digamos exactamente qué hacer. Y eso es lo que aprenderemos este semestre. Cuarto, si sabes R, te será absolutamente fácil aprender Stata (o SPSS).

Este curso está dividido en cuatro grandes unidades.

1. Funciones básicas en R.
2. Estadística descriptiva en R.
3. Introducción a modelos lineales en R.
4. Inferencia causal en R.

Instalación de R

Primero, instala R desde el [sitio Web](#) oficial. Click en “CRAN” (extremo superior izquierdo). Selecciona cualquier *mirror*. Por ejemplo, bájalo desde el *o-Cloud*. Después, baja la interfaz más utilizada, llamada R-Studio. Para esto, anda al [sitio Web](#) oficial, después *Download R-Studio, FREE*, selecciona la versión que sea compatible con tu sistema operativo (Windows, Mac, Ubuntu).

Objetivos Específicos del Curso

1. Lograr establecer una pregunta política/social y un método de identificación que permita verificar la hipótesis de forma causal.
 2. Poder *testear* hipótesis y tener las herramientas para analizar políticas de forma crítica.
 3. Entender las limitaciones de los trabajos empíricos y los *trade offs* existentes al establecer supuestos.
- 📖 Se espera que los estudiantes hagan sus respectivas lecturas *antes* de cada clase para poder participar en el debate crítico que haremos en cada una de ellas. También se espera que los/las estudiantes hagan los ejercicios prácticos clase a clase.

Integridad Académica

- El plagio y la copia serán sancionadas con un 1. En caso de duda pregunta a tu profesor/ayudante. Procura citar todo lo que no sea de tu propiedad intelectual.
 - No se aceptan trabajos atrasados. Si tienes problemas de conectividad, planifica tus envíos con anticipación. Sólo se revisará lo que esté subido a uCampus (aunque esté incompleto). Si no hay nada, tendrás un 1.
 - Ni el ayudante ni el profesor están obligados a responder preguntas (a) después de las 5 pm durante días de semana, (b) durante fines de semana, (c) festivos.
- 📖 No existirán excepciones. Planifica tu trabajo responsablemente.

Política sobre Trabajo Cooperativo

Yo recomiendo el trabajo cooperativo. Es saludable que consultes con tus compañeros/as de curso, y que traten, en la medida de lo posible, de encontrar las soluciones en conjunto. Sin embargo, salvo por el examen final y la presentación final (más sobre esto abajo), todos los trabajos (y sus evaluaciones) serán individuales.

Ayudantía

Las ayudantías se harán por *Zoom*. Y se harán a pedido de los ayudantes. Pero en general, espera tener al menos dos ayudantías al mes. En ellas se verán aspectos relacionados al curso.

Evaluaciones

1. Lecturas y Participación : 10%.

El TA y yo asumiremos durante todo el semestre que has leído. Nosotros empleamos un método de clases interactivo, pero este método necesita de tu participación activa en clases.

Si no puedes asistir a la clase sincrónica, existirán opciones para dejar entradas en la sección *Foro* de uCampus.

2. *Problem Sets*: 10% cada uno, 40% en total.

Estos *problem sets* son ejercicios prácticos. Nosotros te entregaremos un *script* de R junto a una base de datos. Tú tendrás que resolver las preguntas dentro de R y devolvernos ese *script*. El ayudante y el profesor estarán disponibles para resolver preguntas vía email o Zoom.

◇ Aunque no es necesario, sí puedes ocupar recursos externos, como Internet.

◇ Es importante que estas líneas corran bien: el usuario (yo) tiene que ser capaz de ver cómo R ejecuta cada línea, sin estancarse.

◇ Es importante que vayas guiando al usuario (yo) sobre tu raciocinio. Asegúrate de comentar (usando el símbolo #).

3. Un trabajo final obligatorio/no-eximible (30%) y una presentación final (20%, vía Zoom): 50% en total.

En este curso, la actividad final es un trabajo final (30%) que tiene formato de trabajo grupal. Usando una base de datos que nosotros te daremos, tú y tu grupo deberán responder una serie de preguntas. El producto final (i.e. lo que debes entregar) consiste en un *script* de R. La nota es grupal (i.e. todo el grupo recibirá la misma nota). **Los grupos serán de 2 personas.** La formación del grupo es endógena.

El paper (*script*) se puede entregar antes, pero una vez cerrado el plazo, no se recibirán trabajos. Los *scripts* que se entreguen tarde o vía *email* tendrán un 1 (sin opción a reclamo). **No hay excepciones.**

En un formato muy parecido a una conferencia académica (virtual, no presencial), tendrás (junto a tu grupo) que presentar los principales hallazgos (20%). Todos/as presentan. Cada presentación debe durar no menos de 15 minutos, pero nunca más de 20 minutos. Las presentaciones se realizarán virtualmente (i.e. vía Zoom) el último día de clases. Tendrás que ocupar *slides* ("Power Point"). Para tales efectos, tendrás que compartir pantalla desde tu casa, y hacer tu presentación de esa manera.

Les recomiendo "verme" (vía Zoom) en [mis office hours](#) antes del plazo de entrega. Si quieres, [envíame un email](#) con tu borrador, y yo te devolveré comentarios. Vélo como una pre-corrección. Esto es voluntario. También puedes contactar al/la TA. **No se procesarán preguntas durante fines de semana, y/o festivos.**

En resumen:

Textos Mínimos

- Guido Imbens and Donald Rubin (1998). *Causal Inference for Statistics, Social, and Biomedical Sciences*.

	Porcentaje	Porcentaje Acumulado
Participación (cátedra, foro uCampus y ayudantía)	10%	10%
<i>Problem Set #1</i>	10%	20%
<i>Problem Set #2</i>	10%	30%
<i>Problem Set #3</i>	10%	40%
<i>Problem Set #4</i>	10%	50%
Trabajo final grupal	30%	80%
Presentación grupal	20%	100%

- Joshua Angrist and Jorn-Steffen Pischke (2009). *Mostly Harmless Econometrics: An Empiricist's Companion*.
- Jeffrey Wooldridge (2010). *Introducción a la Econometría. Un Enfoque Moderno*.
- Urdinez y Cruz (2019). *AnalizaR Datos Políticos*.
- Krishnan Namboodiri (1984). *Matrix Algebra, an Introduction*.

Textos Recomendados

- Paul Rosenbaum (2010). *Design of Observational Studies*.
- James Monogan (2015). *Political Analysis Using R*.

📖 También se considerarán algunos *papers*. Estos estarán señalados en las fechas indicadas y en la sección de Bibliografía.

Calendario

1. Funciones básicas en R

- **Clase #1**
 - Introducciones: programa de curso, requerimientos, expectativas, etc.
 - *Qué es R?* Instalación de R y RStudio.
 - *Qué es Stata?*
 - **Lecturas:**
 - ◊ Wooldridge (2010): Cap. 1.
 - ◊ Urdinez and Cruz (2019): Cap. 2.
- **Clase #2**
 - Funciones básicas: promedio, `help()`, operadores, tipos de objetos (*character*, *arrays*, fechas, listas, *dataframes*).
 - Cargando bases de datos (I): formatos, etiquetas, tipos de variables, descripción básica.
 - **Lecturas:**
 - ◊ Urdinez and Cruz (2019): Cap. 5.
- **Clase #3**
 - Cargando bases de datos (II): transformaciones, creación de nuevas variables.
 - Manipulando bases de datos: generación de matrices y *dataframes*, `merge`, `append`. Logs.

- **Clase #4**

- Visualización de datos (I): *bar plots* (variable categórica/continua, categórica/categórica), *scatter plots*, histogramas, *time series plots*.
- **Lecturas:**
 - ◊ Urdinez and Cruz (2019): Cap. 4.

- **Clase #5**

- Visualización de datos (II): *plots* más complejos (por categorías), mapas.
- **Lecturas:**
 - ◊ Urdinez and Cruz (2019): Cap. 15.

2. Estadística descriptiva en R

- **Clase #6**

- Estadística descriptiva (I): Teoría de probabilidades: distribuciones, varianza.

- **Clase #7**

- Estadística descriptiva (II): binomial, normal, otras; simulación.

📌 Entrega temario del *Problem set* #1. Una semana de plazo.

3. Introducción a modelos lineales en R

- **Clase #8**

- Introducción a modelos lineales: *Qué es OLS?*
- **Lecturas:**
 - ◊ Wooldridge (2010): 2.1—2.2.

- **Clase #9**

- La mecánica detrás del OLS (II): matrices en R.
- **Lecturas:**
 - ◊ Namboodiri (1984): Caps. 1 y 2.

- **Clase #10**

- Coeficientes.
- **Lecturas:**
 - ◊ Wooldridge (2010): Caps. 3.1—3.2.

- **Clase #11**

- Error, residual y ϵ_i .

- **Clase #12**

- Intervalos de confianza.
- **Lecturas:**
 - ◊ Wooldridge (2010): Cap. 4.3.

- **Clase #13**

- Test de hipótesis (*t test*), errores Tipo I y II, significación estadística (*p-values*).
- **Lecturas:**

- ◇ Wooldridge (2010): Cap. 4.2.

- **Clase #14**

- Términos de interacción. Motivación. Estimación. Interpretación.
- **Lecturas:**
 - ◇ Wooldridge (2010): Cap. 7.4.
 - ◇ Thomas Brambor, William Clark and Matt Golder (2006). *Understanding Interaction Models: Improving Empirical Analyses*. Political Analysis, 14(1): 63—82.

📅 Entrega temario del *Problem set* #2. Una semana de plazo.

- **Clase #15**

- Propiedades numéricas del OLS, Gauss-Markov, sesgo de variable omitida.
- **Lecturas:**
 - ◇ Wooldridge (2010): pp. 89—94, 102—104.

- **Clase #16**

- *Goodness of fit*, “coeficiente de determinación” (r^2), predicción.
- **Lecturas:**
 - ◇ Wooldridge (2010): pp. 40—41, Cap. 6.3.
 - ◇ Gary King (1986). *How Not to Lie With Statistics: Avoiding Common Mistakes in Quantitative Political Science*. American Journal of Political Science, 30(3): 666—687.

- **Clase #17**

- Problemas y *post-estimation*: multicolinealidad perfecta, heteroskedasticidad, no linealidad, *outliers*, no normalidad de residuos, auto-correlación.
- **Lecturas:**
 - ◇ Wooldridge (2010): Caps. 8 y 9.5.

📅 Entrega temario del *Problem set* #3. Una semana de plazo.

4. Inferencia causal en R

- **Clase #18**

- Inferencia Causal: El *Problema Fundamental* en Inferencia Causal, el Supuesto de la “Ignorabilidad” y el “*Potential Outcomes Framework*”.
- **Lecturas:**
 - ◇ Imbens and Rubin (2015): Ch. 1.

- **Clase #19**

- Variables instrumentales y *two-stage least squares*.
- **Lecturas:**
 - ◇ Angrist and Pischke (2009): 4.1—4.2.

📅 Entrega temario del *Problem set* #4. Una semana de plazo.

- **Clase #20**

- Regression discontinuity designs: *Sharp Designs*.
- **Lecturas:**

◇ Angrist and Pischke (2009): 6—6.1.

- **Clase #21**

- Regression discontinuity designs: *Fuzzy Designs*.

- **Lecturas:**

- ◇ Angrist and Pischke (2009): 6.2.

- **Clase #22**

- Incorporando el elemento *tiempo*: fixed effects, differences-in-differences.

- **Lecturas:**

- ◇ Angrist and Pischke (2009): Ch. 5.

📌 Entrega temario del trabajo final.

- **Última Clase**

- Presentaciones Grupales. Formato “conferencia online”.

References

- Angrist, Joshua, and Jorn-Steffen Pischke. 2009. *Mostly Harmless Econometrics: An Empiricist's Companion*. 392. Princeton University Press.
- Brambor, Thomas, William Clark, and Matt Golder. 2006. "Understanding Interaction Models: Improving Empirical Analyses." *Political Analysis* 14 (01): 63–82.
- Imbens, Guido, and Donald Rubin. 2015. *Causal Inference for Statistics, Social, and Biomedical Sciences*. Cambridge University Press.
- King, Gary. 1986. "How Not to Lie with Statistics: Avoiding Common Mistakes in Quantitative Political Science." *American Journal of Political Science* 30 (3): 666–687.
- Monogan, James. 2015. *Political Analysis Using R*. Springer.
- Namboodiri, Krishnan. 1984. *Matrix Algebra: An Introduction*, 1–99. Sage.
- Rosenbaum, Paul. 2010. *Design of Observational Studies*. Springer Series in Statistics. Springer New York.
- Urdinez, Francisco, and Andrés Cruz. 2019. *AnalizaR Datos Políticos*. Edited by Francisco Urdinez and Andrés Cruz. <https://arcruzo.github.io/libroadp/>.
- Wooldridge, Jeffrey. 2010. *Introducción a la Econometría. Un Enfoque Moderno*. 4th. Cengage Learning.